

時間序列分析  
—總體經濟與財務金融之應用—  
定態時間序列 II: ARMA 模型

陳旭昇

2013.12

- 1 移動平均模型
- 2 ARMA 模型
- 3 ARMA 模型之估計
- 4 ARMA 模型之預測以及衝擊反應函數
- 5 Wold Representation 定理
- 6 實例應用:  $ARMA(p,q)$  模型之估計

# 移動平均模型

## 定義 ( $q$ 階移動平均模型)

若隨機過程  $\{y_T\}$  為現在與過去  $q$  期隨機衝擊  $(\varepsilon_t, \varepsilon_{t-1}, \dots, \varepsilon_{t-q})$  之加權平均:

$$y_t = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q},$$

$$\varepsilon_t \sim^{i.i.d.} (0, \sigma^2),$$

則稱為  $q$  階移動平均模型 ( $q$ -order moving average model), 簡稱 MA( $q$ ) 模型。

# 移動平均模型

- 無窮階移動平均模型  $MA(\infty)$  為

$$y_t = \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j}.$$

- $MA(\infty)$  定態之條件為

$$\sum_{j=0}^{\infty} |\psi_j| < \infty,$$

亦即  $\{\psi_j\}$  為「絕對可加」(absolutely summable)。因此, 有限階次移動平均模型  $MA(q)$  必為定態。

# 移動平均模型

## 性質 (MA( $q$ ) 的可逆性)

給定

$$y_t = \theta(L)\varepsilon_t,$$

如果  $\theta(z) = 0$  之根落於單位圓之外, 則 MA( $q$ ) 序列可以寫成:

$$\frac{1}{\theta(L)}y_t = \varepsilon_t,$$

且稱該 MA( $q$ ) 序列具「可逆性」(invertible)。

# 移動平均模型

## 性質 (Absolutely Summable Inverses of Lag Polynomials)

給定一個  $p$  階落後運算多項式:

$$\beta(L) = 1 - \beta_1 L - \beta_2 L^2 - \cdots - \beta_p L^p.$$

如果  $\beta(z) = 0$  的根均落在單位圓之外, 則

$$\beta(L)^{-1} = \varphi(L) = \varphi_0 + \varphi_1 L + \varphi_2 L^2 + \cdots$$

其中

$$\sum_{j=0}^{\infty} |\varphi_j| < \infty,$$

亦即  $\beta(L)$  的逆落後運算多項式之係數為「絕對可加」。

# ARMA 模型

- 將 AR 與 MA 模型結合在一起, 考慮一個  $ARMA(p, q)$  模型:

$$y_t = \beta_1 y_{t-1} + \cdots + \beta_p y_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}$$

- 令

$$\beta(L) = 1 - \beta_1 L - \beta_2 L^2 - \cdots - \beta_p L^p$$

$$\theta(L) = 1 + \theta_1 L + \theta_2 L^2 + \cdots + \theta_q L^q$$

- $ARMA(p, q)$  可寫成

$$\beta(L)y_t = \theta(L)\varepsilon_t$$

# ARMA 模型

性質 (ARMA  $(p,q)$  模型的定態條件)

給定

$$\beta(L)y_t = \theta(L)\varepsilon_t,$$

如果  $\beta(z) = 0$  的根均落在單位圓之外, 則  $y_t$  為定態。



## ARMA 模型

若  $y_t$  為定態, 則  $\text{ARMA}(p,q)$  可寫成  $\text{MA}(\infty)$ :

$$\begin{aligned}
 y_t &= \underbrace{\beta(L)^{-1}\theta(L)}_{\psi(L)} \varepsilon_t \\
 &= \left[ \frac{1 + \theta_1 L + \theta_2 L^2 + \cdots + \theta_q L^q}{1 - \beta_1 L - \beta_2 L^2 - \cdots - \beta_p L^p} \right] \varepsilon_t \\
 &= \psi(L) \varepsilon_t \\
 &= \varepsilon_t + \psi_1 \varepsilon_{t-1} + \psi_2 \varepsilon_{t-2} + \cdots \\
 &= \text{MA}(\infty).
 \end{aligned}$$

其中  $\psi_0 = 1$ ,

$$\sum_{j=0}^{\infty} |\psi_j| < \infty.$$

# ARMA 模型

性質 (ARMA( $p, q$ ) 模型的可逆條件)

給定

$$\beta(L)y_t = \theta(L)\varepsilon_t,$$

如果  $\theta(z) = 0$  的根均落在單位圓之外, 則  $y_t$  為可逆。

- 若  $\theta(z) = 0$  的根均落在單位圓之外, 則

$$\underbrace{\theta(L)^{-1}\beta(L)}_{b(L)} y_t = \varepsilon_t$$

# ARMA 模型

- 亦即

$$b(L)y_t = \varepsilon_t,$$

其中

$$b(L) = 1 - b_1L - b_2L^2 - \dots$$

- 因此, ARMA  $(p,q)$  模型可寫成 AR( $\infty$ ):

$$y_t = \varepsilon_t + b_1y_{t-1} + b_2y_{t-2} + \dots = \text{AR}(\infty).$$

# ARMA 模型之估計

- 欲估計 ARMA 模型有一個大問題是: 我們有資料  $\{y_T, y_{T-1}, \dots, y_1\}$ , 卻無法觀察到  $\{\varepsilon_T, \varepsilon_{T-1}, \dots, \varepsilon_1\}$ 。
- 一種做法是給定起始值下以遞迴 (recursively) 的方式找出  $\{\varepsilon_T, \varepsilon_{T-1}, \dots, \varepsilon_1\}$ , 然後以非線性最小平方法 (nonlinear least square method) 將  $\beta_j$  與  $\theta_j$  估計出來。

# ARMA 模型之估計

給定 ARMA( $p, q$ ) 模型,

$$y_t = \beta_1 y_{t-1} + \cdots + \beta_p y_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}$$

假設我們擁有資料  $\{y_t\}_{t=1}^T$ , 以及起始值:

$$\underline{y}_0 = (y_0, y_{-1}, \dots, y_{-p+1})$$

$$\underline{\varepsilon}_0 = (\varepsilon_0, \varepsilon_{-1}, \dots, \varepsilon_{-q+1})$$

且

$$\varepsilon_t \sim^{i.i.d.} N(0, \sigma^2).$$

## ARMA 模型之估計

令  $\beta = (\beta_1, \dots, \beta_p)$ ,  $\theta = (\theta_1, \dots, \theta_q)$ , 則聯合機率分配為

$$\begin{aligned}
 & f(y_T, y_{T-1}, \dots, y_1 | \beta, \theta, \sigma^2, \underline{y_0}, \underline{\varepsilon_0}) \\
 &= f(y_T | y_{T-1}, \dots, y_1, \beta, \theta, \sigma^2, \underline{y_0}, \underline{\varepsilon_0}) \cdot f(y_{T-1}, \dots, y_1 | \beta, \theta, \sigma^2, \underline{y_0}, \underline{\varepsilon_0}) \\
 &\quad \vdots \\
 &= \prod_{t=1}^T f(y_t | y_{t-1}, \dots, y_1, \beta, \theta, \sigma^2, \underline{y_0}, \underline{\varepsilon_0})
 \end{aligned}$$

# ARMA 模型之估計

由於給定  $(y_{t-1}, \dots, y_1, \underline{y_0}, \underline{\varepsilon_0}, \beta, \theta, \sigma^2)$ ,  $y_t$  的條件分配為

$$\begin{aligned} y_t | (y_{t-1}, \dots, y_1, \underline{y_0}, \underline{\varepsilon_0}, \beta, \theta, \sigma^2) \\ \sim N(\beta_1 y_{t-1} + \dots + \beta_p y_{t-p} + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}, \sigma^2) \end{aligned}$$

我們可以得到

$$\begin{aligned} f(y_t | y_{t-1}, y_{t-2}, \dots, y_1, \beta, \theta, \sigma^2, \underline{y_0}, \underline{\varepsilon_0}) \\ = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{(y_t - \beta_1 y_{t-1} - \dots - \beta_p y_{t-p} - \theta_1 \varepsilon_{t-1} - \dots - \theta_q \varepsilon_{t-q})^2}{2\sigma^2} \right\} \end{aligned}$$

# ARMA 模型之估計

因此對數概似函數為

$$\log L = \frac{-T}{2} \log \sigma^2 - \frac{T}{2} \log 2\pi - \frac{1}{2} \sum_{t=1}^T \frac{(y_t - \beta_1 y_{t-1} - \cdots - \beta_p y_{t-p} - \theta_1 \varepsilon_{t-1} - \cdots - \theta_q \varepsilon_{t-q})^2}{\sigma^2}$$

由於我們無法觀察到  $\{\varepsilon_T, \varepsilon_{T-1}, \dots, \varepsilon_1\}$ , 我們將以遞迴 (recursively) 的方式將它們找出來。首先注意到,

$$\varepsilon_t = y_t - \beta_1 y_{t-1} - \cdots - \beta_p y_{t-p} - \theta_1 \varepsilon_{t-1} - \cdots - \theta_q \varepsilon_{t-q}.$$



# ARMA 模型之估計

因此,

- 1 給定  $\underline{y_0}, \underline{\varepsilon_0}, y_1, \beta, \theta$  我們可以得到  $\varepsilon_1(\beta, \theta)$
- 2 給定  $\underline{y_0}, \underline{\varepsilon_0}, y_1, y_2, \varepsilon_1(\beta, \theta), \beta, \theta$  我們可以得到  $\varepsilon_2(\beta, \theta)$
- 3 依此類推, 我們可以得到  $\varepsilon_t(\beta, \theta), t = 1, 2, \dots, T$ , 注意到  $\varepsilon_t(\beta, \theta)$  為  $\beta$  與  $\theta$  的非線性函數。

# ARMA 模型之估計

我們可以得到估計式為

$$(\hat{\beta}_{ml}, \hat{\theta}_{ml}) = \arg \min \sum_{t=1}^T \left( y_t - \beta_1 y_{t-1} - \cdots - \beta_p y_{t-p} \right. \\ \left. - \theta_1 \varepsilon_{t-1}(\beta, \theta) - \cdots - \theta_q \varepsilon_{t-q}(\beta, \theta) \right)^2$$

$$\hat{\sigma}_{ml}^2 = \frac{1}{T} \sum_{t=1}^T \left( y_t - \hat{\beta}_1 y_{t-1} - \cdots - \hat{\beta}_p y_{t-p} - \hat{\theta}_1 \varepsilon_{t-1}(\hat{\beta}, \hat{\theta}) - \cdots - \hat{\theta}_q \varepsilon_{t-q}(\hat{\beta}, \hat{\theta}) \right)^2 \\ = \frac{1}{T} \sum_{t=1}^T \hat{\varepsilon}_t(\hat{\beta}, \hat{\theta})^2$$

# ARMA 模型之預測以及衝擊反應函數

我們可以將一個  $ARMA(p,q)$  模型:

$$y_t = \beta_1 y_{t-1} + \cdots + \beta_p y_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}$$

改寫成一階形式:

$$\begin{bmatrix} y_t \\ y_{t-1} \\ \vdots \\ y_{t-p+1} \\ \varepsilon_t \\ \varepsilon_{t-1} \\ \vdots \\ \varepsilon_{t-q+1} \end{bmatrix} = \begin{bmatrix} \beta_1 & \cdots & \cdots & \cdots & \beta_p & \theta_1 & \cdots & \cdots & \cdots & \theta_q \\ 1 & 0 & \cdots & \cdots & 0 & 0 & 0 & \cdots & \cdots & 0 \\ 0 & \ddots & \cdots & \cdots & \vdots & 0 & \ddots & \cdots & \cdots & \vdots \\ \vdots & & \ddots & & \vdots & \vdots & & \ddots & & \vdots \\ 0 & \cdots & \cdots & 1 & 0 & 0 & \cdots & \cdots & 0 & 0 \\ 0 & \cdots & \cdots & \cdots & 0 & 0 & \cdots & \cdots & \cdots & 0 \\ 0 & 0 & \cdots & \cdots & 0 & 1 & 0 & \cdots & \cdots & 0 \\ 0 & \ddots & \cdots & \cdots & \vdots & 0 & \ddots & \cdots & \cdots & \vdots \\ \vdots & & \ddots & & \vdots & \vdots & & \ddots & & \vdots \\ 0 & \cdots & \cdots & 0 & 0 & 0 & \cdots & \cdots & 1 & 0 \end{bmatrix} \begin{bmatrix} y_{t-1} \\ y_{t-2} \\ \vdots \\ y_{t-p} \\ \varepsilon_{t-1} \\ \varepsilon_{t-2} \\ \vdots \\ \varepsilon_{t-q} \end{bmatrix} + \begin{bmatrix} 1 \\ 0 \\ \vdots \\ 0 \\ 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix} \varepsilon_t$$

# ARMA 模型之預測以及衝擊反應函數

亦即

$$\underbrace{Y_t}_{(p+q) \times 1} = \underbrace{\Phi}_{(p+q) \times (p+q)} Y_{t-1} + \epsilon_t$$

$$= \sum_{j=0}^{\infty} \Phi^j \epsilon_{t-j}$$

- 預測式

$$E_t(y_{t+j}) = [1 \ 0 \cdots 0] \Phi^j Y_t.$$

# ARMA 模型之預測以及衝擊反應函數

## ● 衝擊反應函數

$$\Psi(j) = \frac{\partial y_{t+j}}{\partial \varepsilon_t} = [1 \ 0 \cdots 0] \Phi^j \begin{bmatrix} 1 \\ 0 \\ \vdots \\ 0 \\ 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

實務上則以  $\hat{\Phi}$  替代之。

# Wold Representation 定理

## 定理 (Wold Representation 定理)

任何均值為零的定態時間序列  $\{y_t\}$  都能寫成

$$y_t = \sum_{j=0}^{\infty} \varphi_j \varepsilon_{t-j} = \varphi(L) \varepsilon_t.$$

# Wold Representation 定理

其中

- ❶  $\varepsilon_t \equiv y_t - P(y_t | H_{t-1})$  稱為干擾項 (innovation), 乃是將序列  $y_t$  投射到  $H_t = S_p[y_t, y_{t-1}, y_{t-2}, \dots]$  的投射殘差 (projection residual)
- ❷  $\varphi(L) = 1 + \varphi_1 L + \varphi_2 L^2 + \dots$
- ❸  $\sum_{j=0}^{\infty} \varphi_j^2 < \infty, \varphi_0 = 1$  ( $y_t$  為定態)
- ❹  $\varepsilon_t \sim WN(0, \sigma^2)$
- ❺  $\varphi(z) = 0$  的根均落於單位圓外 ( $y_t$  可逆)
- ❻  $\{\varphi_j\}$  與  $\{\varepsilon_t\}$  具唯一性 (unique)

# Wold Representation 定理

- 值得注意的是, Wold Representation 定理是  $\{y_t\}$  的「一種」表示法, 卻不是「唯一」的表示法。而  $\{\varphi_j\}$  與  $\{\varepsilon_t\}$  的唯一性是指 Wold Representation 只有一個,「僅此一家, 別無分號」。也就是說, 如果兩個時間序列具有相同的 Wold Representation, 則它們為相同的時間序列。



# Wold Representation 定理

- Wold Representation 定理說明了任何定態時間序列都能以一個線性模型表示之。然而, 問題是 Wold Representation 定理告訴我們此線性模型為無窮多個干擾項所組成, 因而  $\varphi(L)$  中就有無窮多個有待估計的參數, 這在實務上並不可行。
- 一個實務上的解決方式是以  $\frac{\theta(L)}{\beta(L)}$  來近似 (approximate)  $\varphi(L)$ ,

$$\varphi(L) \approx \frac{\theta(L)}{\beta(L)},$$

$$\beta(L) = 1 - \beta_1 L - \beta_2 L^2 - \cdots - \beta_p L^p,$$

$$\theta(L) = 1 + \theta_1 L + \theta_2 L^2 + \cdots + \theta_q L^q.$$

亦即, 以一個  $\text{ARMA}(p,q)$  來近似 Wold Representation。

實例應用: ARMA( $p,q$ ) 模型之估計

圖 : ARMA(2,1) 估計結果

Dependent Variable: LS Method: Least Squares Date: 09/05/07 Time: 16:43 Sample (adjusted): 1972:3 2007:4 Included observations: 142 after adjustments Convergence achieved after 8 iterations Backcast: 1972:2				
	Coefficient	Std. Error	t-Statistic	Prob.
C	3.464545	0.085820	40.36971	0.0000
AR(1)	1.516098	0.151257	10.02330	0.0000
AR(2)	-0.533734	0.149067	-3.580496	0.0005
MA(1)	-0.084751	0.178677	-0.474325	0.6360
R-squared	0.983602	Mean dependent var	3.497304	
Adjusted R-squared	0.983245	S.D. dependent var	0.147681	
S.E. of regression	0.019116	Akaike info criterion	-5.048818	
Sum squared resid	0.050428	Schwarz criterion	-4.965556	
Log likelihood	362.4661	Hannan-Quinn criter.	1.998440	
F-statistic	6.2E-123			
Inverted AR Roots	.96	.56		
Inverted MA Roots	.08			

實例應用: ARMA( $p,q$ ) 模型之估計

圖: AR 與 MA 之根的倒數

